

PREDICCIÓN DE SINIESTROS VIALES EN ARGENTINA

Asignatura: Programación Avanzada para Ciencias de Datos

Integrantes:

Damián Jorge Cordero

Luis Eduardo Santillán Cruz

Ricardo Alberto Ureña

DE LOS DATOS A LA ARQUITECTURA

Dataset Público Original

- Registro detallado del incidente
- [1 fila = 1 víctima]
- Datos categóricos: Edades, Gravedad, Rol.



Transformación Predictiva

- Agrupación temporal para Regresión
- [Víctimas totales por día]
- Nuevos Features: Año, Mes, Día de la semana.

Stack Tecnológico Utilizado:



PIPELINE DE MACHINE LEARNING

1. Partición de Datos

División del dataset histórico.

[80% Entrenamiento / 20% Prueba]



2. Preprocesamiento

Uso de Pipelines de Scikit-Learn.

[StandardScaler]

(Evita fuga de información).



3. Entrenamiento

Comparación de Algoritmos
de Ensamble:

[Random Forest]

[Gradient Boosting]

Nota: Todo el proceso, la configuración y las predicciones se guardan automáticamente en MongoDB Atlas.

EVALUACIÓN DE MODELOS PREDICTIVOS

Métricas Clave:



$R^2 = 0.53$

El modelo logra explicar el 53% de la variabilidad de los accidentes usando solo la fecha.



$MAE = 6.63$


Margen de error absoluto promedio de ~6.6 víctimas por día.



$RMSE = 8.38$


Penaliza fuertemente los errores grandes en días con picos atípicos de accidentes.

Comparación de Rendimiento: Random Forest vs Gradient Boosting



ANÁLISIS DE FACTORES DETERMINANTES

¿Qué factores impactan más en los siniestros viales? (Importancia de Variables)



Descubrimientos del Modelo:



La Estacionalidad es clave.

Es el factor que más influye en los picos de accidentalidad, dominando las predicciones del algoritmo.



La dinámica semanal es secundaria.

El Día de la Semana tiene un impacto menor de lo esperado frente a factores macro, siendo superado por la estacionalidad del Mes y el Año.

PROYECCIÓN TEMPORAL: REALIDAD VS PREDICCIÓN

Hallazgos Clave:



Alta capacidad predictiva

El modelo sigue de cerca la realidad a lo largo del tiempo, capturando tendencias y picos.



Comportamiento conservador en extremos


El modelo es altamente preciso en días rutinarios, pero tiende a subestimar los picos atípicos de mayor accidentalidad.



Utilidad para la planificación

Permite anticipar escenarios y mejorar la asignación de recursos en seguridad vial.

Accidentes Diarios (Datos de Prueba): Realidad vs Modelo Predictivo



LECCIONES APRENDIDAS Y MEJORAS FUTURAS



Aprendizajes Técnicos

- **Preprocesamiento Crítico:** La correcta limpieza y la agrupación temporal de los datos fueron fundamentales para la precisión predictiva.
- **Persistencia en la Nube:** La integración con MongoDB Atlas garantiza que el modelo sea auditable y escalable.
- **Pipelines:** Fundamental para evitar el "Data Leakage" y asegurar resultados reales.



Mejoras del Modelo

- **Variables Externas:** Integrar datos climáticos (lluvia/niebla) y calendario de feriados para capturar anomalías.
- **Geolocalización:** Predecir no solo "cuándo", sino "dónde", sumando coordenadas GPS al modelo.
- **Algoritmos Avanzados:** Probar redes neuronales (LSTM) específicas para series temporales.

¡MUCHAS GRACIAS POR SU ATENCIÓN!