

# PREDICCIÓN DE SINIESTROS VIALES EN ARGENTINA

**Asignatura:** Programación Avanzada para Ciencias de Datos

**Integrantes:**

Damián Jorge Cordero

Luis Eduardo Santillán Cruz

Ricardo Alberto Ureña

# DE LOS DATOS A LA ARQUITECTURA

## Dataset Público Original

- Registro detallado del incidente
- [ 1 fila = 1 víctima ]
- Datos categóricos: Edades, Gravedad, Rol.



## Transformación Predictiva

- Agrupación temporal para Regresión
- [ Víctimas totales por día ]
- Nuevos Features: Año, Mes, Día de la semana.

### Stack Tecnológico Utilizado:



# PIPELINE DE MACHINE LEARNING

---

## 1. Partición de Datos

División del dataset histórico.

[ 80% Entrenamiento / 20% Prueba ]



## 2. Preprocesamiento

Uso de Pipelines de Scikit-Learn.

[ StandardScaler ]

(Evita fuga de información).



## 3. Entrenamiento

Comparación de Algoritmos  
de Ensamble:

[ Random Forest ]

[ Gradient Boosting ]

*Nota: Todo el proceso, la configuración y las predicciones se guardan automáticamente en MongoDB Atlas.*

# EVALUACIÓN DE MODELOS PREDICTIVOS

## Métricas Clave:

$$R^2 = 0.10$$

Al predecir bloques de tiempo futuros y reales, el modelo logra explicar el 10% de la variabilidad usando estrictamente la fecha.


$$MAE = 8.23$$

Margen de error absoluto promedio de ~8.2 víctimas por día.

$$RMSE = 10.86$$

El indicador se eleva porque penaliza fuertemente los errores en días con picos atípicos de accidentes.

Comparación de Rendimiento: Random Forest vs Gradient Boosting





# ANÁLISIS DE FACTORES DETERMINANTES

## Descubrimientos del Modelo:



### La Estacionalidad es clave:


El Mes (32.79%) y el Día (23.39%) dominan por completo las decisiones del algoritmo. Esto demuestra que los picos de siniestros responden de forma cíclica y predecible según la época del año y el momento del mes.



### La dinámica semanal y anual es secundaria:

El Día de la Semana (22.87%) y el Año (20.96%) pasaron a un segundo plano. Al evaluar el modelo cronológicamente, el factor 'Año' pierde peso, demostrando que el comportamiento del tránsito actual se explica mucho mejor por el contexto estacional inmediato que por tendencias históricas a largo plazo.

¿Qué factores impactan más en los siniestros viales? (Importancia de Variables)



# PROYECCIÓN TEMPORAL: REALIDAD VS PREDICCIÓN

## Hallazgos Clave:



### Alta capacidad de tendencia:

La línea violeta (predicción) copia de forma notable el "ritmo" y la inercia de la línea roja (realidad) a lo largo de todo el año 2024. El modelo asimila perfectamente cuándo el volumen base de accidentes va a subir o bajar.



### Efecto suavizado en extremos:


Al evaluar cronológicamente, se hace evidente que el algoritmo es estructuralmente conservador. Tiende a subestimar los picos de días caóticos (donde la realidad supera las 60 víctimas) y a sobreestimar los mínimos, manteniéndose estable en un corredor predictivo de entre 20 y 45 víctimas diarias.



### Valor para la planificación:

A pesar de no replicar el "ruido" o las anomalías de los días extremos, la fidelidad con la que captura la tendencia estacional lo convierte en una herramienta óptima para la asignación anticipada de recursos de seguridad y salud urbana.

Accidentes Diarios (Datos de Prueba): Realidad vs Modelo Predictivo





# LECCIONES APRENDIDAS Y MEJORAS FUTURAS



## Aprendizajes Técnicos

- **Preprocesamiento Crítico:** La correcta limpieza y la agrupación temporal de los datos fueron fundamentales para la precisión predictiva.
- **Persistencia en la Nube:** La integración con MongoDB Atlas garantiza que el modelo sea auditable y escalable.
- **Pipelines:** Fundamental para evitar el "Data Leakage" y asegurar resultados reales.



## Mejoras del Modelo

- **Variables Externas:** Integrar datos climáticos (lluvia/niebla) y calendario de feriados para capturar anomalías.
- **Geolocalización:** Predecir no solo "cuándo", sino "dónde", sumando coordenadas GPS al modelo.
- **Algoritmos Avanzados:** Probar redes neuronales (LSTM) específicas para series temporales.

**¡MUCHAS GRACIAS POR SU ATENCIÓN!**